



机器学习 第一讲(续)

主要内容

- 围绕第一讲的问题3，从数据预测中的另一个任务——**分类预测**，看经典统计方法与机器学习算法的互补性。基于**案例**，涉及如下方面：
 - 经典统计方法如何解决分类预测问题？
 - 分类预测模型如何评价？
 - 经典统计方法在分类预测中的优势和不足？学习机器学习算法的必要性？
 - **分类预测中的非线性特点**
- 进一步讨论以下几个问题：
 - 问题4：经典统计方法与机器学习算法的共通处？
 - 问题5：本课程聚焦机器学习的哪些方面？
 - 算法、角度

数据预测中的分类预测问题

• 案例三：根据污染物浓度对空气质量等级进行预测：分类预测

	日期	AQI	质量等级	PM2.5	PM10	SO2	CO	NO2	O3
0	2014-01-01	81.0	良	45.0	111.0	28.0	1.5	62.0	52.0
1	2014-01-02	145.0	轻度污染	111.0	168.0	69.0	3.4	93.0	14.0
2	2014-01-03	74.0	良	47.0	98.0	29.0	1.3	52.0	56.0
3	2014-01-04	149.0	轻度污染	114.0	147.0	40.0	2.8	75.0	14.0
4	2014-01-05	119.0	轻度污染	91.0	117.0	36.0	2.3	67.0	44.0

- 空气质量等级的多分类预测
- 空气质量等级的二分类预测(简单)
 - 无污染(优+良)、有污染(轻度+中度+重度+严重)
- 问：

- 哪些可作为输入变量？谁是输出变量，其取值特点(0/1)？

→AQI是空气质量指数 (Air Quality Index) 的简称，是新环境空气质量标准用于描述空气质量状况的指标。

空气质量指数 (AQI)

AQI 值	AQI 分类	AQI 颜色
0 - 50	优	绿色
51 - 100	良	黄色
101 - 150	轻度污染	橙色
151 - 200	中度污染	红色
201 - 300	重度污染	紫色
301 - 500	严重污染	褐红色

→按照AQI的数值大小将空气质量状况分成了优、良、轻度污染、中度污染、重污染、严重污染六个等级。

质量等级	
良	827
轻度污染	470
优	377
中度污染	252
重度污染	127
严重污染	43

二分类预测中的经典统计方法

• 问：

- 可否利用一般线性回归模型解决二分类($y = 0/1$)预测问题？

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u, \quad E(y|x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k.$$

$$P(y = 1|x) = E(y|x) \quad P(y = 1|x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k,$$

- 对响应概率建模，称为一般线性概率模型
- 预测结果以怎样的方式给出？ 概率阈值0.5
- 一般线性概率模型有什么不足吗？
 - 能保证模型给出的概率预测值在0-1范围内吗？
 - 概率与输入变量取值之间的关系一般是线性的吗？
 - 例：收入和购买某奢侈品的概率

二分类预测中的经典统计方法

- 一般线性概率模型拓展：**二项Logistic回归模型**，经典的二分类($y = 0/1$)预测模型

$$P(y = 1|x) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k,$$


$$\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

连接函数
Logit P

$$P = \frac{1}{1 + \exp(-f(\mathbf{x}))}$$

$$\text{Logit } \hat{P} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p$$

- 问：这种变换处理解决了哪些问题？
 - 预测值范围的问题
 - 概率 P 与输入变量取值间的非线性特征



$$P(y_i = 1 | \mathbf{x}) > 0.5, \hat{y}_i = 1$$

$$P(y_i = 1 | \mathbf{x}) \leq 0.5, \hat{y}_i = 0$$

- 案例三的分析：二项Logistic回归模型 $\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 PM2.5 + \beta_2 PM10$

• 问：为什么采用二项Logistic回归？假设、可解释性

- Logistic回归模型的可解释性 $\log\left(\frac{P}{1-P}\right) = \beta_0 + \mathbf{x}\boldsymbol{\beta}$ β 的实际意义不明确

- 有： $\Omega = \frac{P}{1-P} = \exp(\beta_0 + \mathbf{x}\boldsymbol{\beta})$

优势(Odds)

- 例： x_1, x_2 两个输入变量，
当 x_2 不变 x_1 从0变化到1时：

$$\Omega = \exp(\beta_0 + \beta_2 x_2)$$

$$\Omega^* = \exp(\beta_1 + \beta_0 + \beta_2 x_2) = \Omega \exp(\beta_1)$$

优势比
(Odds Ratio)

$$\frac{\Omega^*}{\Omega} = \exp(\beta_1) \quad \text{输入变量 } x_1 \text{ 变化一个单位引起的优势比为 } \exp(\beta_1)$$

$$\exp(\beta_1) = \frac{\Omega^*}{\Omega} = \frac{P(y=1 | x_1=1, x_2)}{1-P(y=1 | x_1=1, x_2)} \bigg/ \frac{P(y=1 | x_1=0, x_2)}{1-P(y=1 | x_1=0, x_2)}$$

$$OR_{x_i} = \exp(\beta_i)$$

$$= \frac{P(y=1 | x_1=1, x_2)}{P(y=1 | x_1=0, x_2)} \times \frac{1-P(y=1 | x_1=0, x_2)}{1-P(y=1 | x_1=1, x_2)}$$

$$\approx \frac{P(y=1 | x_1=1, x_2)}{P(y=1 | x_1=0, x_2)}$$

接近0时

其他变量不变，输入变量 x_1 变化一个单位引起响应概率比(相对风险)近似为 $\exp(\beta_1)$

• 案例三的分析：二项Logistic回归模型

$$\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 PM2.5 + \beta_2 PM10$$

chapter3-3.ipynb

• 注意：数据的重编码！

```
1 data = pd.read_excel('北京市空气质量数据.xlsx')
2 data = data.replace(0, np.NaN)
3 data = data.dropna()
4 data['有无污染'] = data['质量等级'].map({'优':0, '良':0, '轻度污染':1, '中度污染':1, '重度污染':1, '严重污染':1})
5 print(data['有无污染'].value_counts())
6 fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(15, 6), dpi=150)
7 axes[0].scatter(data.loc[data['有无污染']==0, 'PM2.5'], data.loc[data['有无污染']==0, 'PM10'], c='cornflowerblue', marker='o', label='无污染', a
8 axes[0].scatter(data.loc[data['有无污染']==1, 'PM2.5'], data.loc[data['有无污染']==1, 'PM10'], c='grey', marker='+', label='有污染', alpha=0.4)
9 axes[0].set_title('有无污染与PM2.5和PM10', fontsize = 14)
10 axes[0].set_xlabel('PM2.5', fontsize = 14)
11 axes[0].set_ylabel('PM10', fontsize = 14)
12 axes[0].legend()
13 X = data[['PM2.5', 'PM10']]
14 y = data['有无污染']
15 modelLR = LM.LogisticRegression()
16 modelLR.fit(X, y)
17 print('截距项:%f'%modelLR.intercept_)
18 print('回归系数:', modelLR.coef_)
19 print('优势比{0}'.format(np.exp(modelLR.coef_)))
```

0	1204
1	892

Name: 有无污染, dtype: int64
截距项:-4.858429
回归系数: [[0.05260358 0.01852681]]
优势比[[1.05401173 1.0186995]]


$$\text{Logit } P = -4.85 + 0.05PM2.5 + 0.02PM10$$

• 问：

- 模型系数的含义？
- 预测模型需关注什么？
 - 评价指标？

$$\frac{P(y = 1 | PM2.5 = level1 + \Delta level, PM10)}{P(y = 1 | PM2.5 = level1, PM10)} \approx 1.05$$

$\Delta level = 1$



- 二分类预测模型中的评价指标
 - 混淆矩阵和衍生出的评价指标

实际 类别值	预测类别值	
	1	0
1	TP	FN
0	FP	TN

$$\text{总正确率} = \frac{TP+TN}{N}$$

$$\text{总错判率} = \frac{FN+FP}{N}$$

```
print('总错判率:%f'%(1-modelLR.score(X,y)))
```

总错判率:0.153149

- 问：
 - 下表中的总正确率指标你认为可以采纳吗？
 - 为什么？是什么问题导致的？
 - 还需要衍生出哪些评价指标？

		预测值		合计	正确率
		0	1		
实际值	0	140	20	160	87.50%
	1	40	0	40	0%
	合计	180	20	200	70%

$$\text{敏感性} = \frac{TP}{TP+FN}$$

$$\text{特异性} = \frac{TN}{TN+FP}$$

TPR(真正率)

TNR 1-TNR=FPR(假正率)



$$\text{查准率} = \frac{TP}{TP+FP}$$

$$\text{查全率} = \frac{TP}{TP+FN}$$

查全率也称召回率(Recall)

$$\frac{1}{F1} = \frac{1}{2} \left(\frac{1}{P} + \frac{1}{R} \right)$$

$$\text{F1 分数} = \frac{2 \times P \times R}{P+R} = \frac{2 \times TP}{N+TP-TN}$$

- 问：如何更直观理解二项Logistic回归模型--几何含义？
 - 基于案例三，从观测预测结果的角度讨论



chapter3-3.ipynb

```
20 X01 = np.linspace(data[['PM2.5']].values.min(), data[['PM2.5']].values.max(), 120)
21 X02 = np.linspace(data[['PM10']].values.min(), data[['PM10']].values.max(), 120)
22 X01, X02 = np.meshgrid(X01, X02)
23 X0 = np.hstack((X01.reshape(14400, 1), X02.reshape(14400, 1)))
24 Y0hat = modelLR.predict(X0).reshape(X01.shape)
25 axes[1].contourf(X01, X02, Y0hat, alpha=0.4, cmap=plt.cm.coolwarm)
26 axes[1].scatter(data.loc[data['有无污染']==0, 'PM2.5'], data.loc[data['有无污染']==0, 'PM10'], c='cornflowerblue', marker='o', label='无污染',
27 axes[1].scatter(data.loc[data['有无污染']==1, 'PM2.5'], data.loc[data['有无污染']==1, 'PM10'], c='grey', marker='+', label='有污染', s=50, alpha=
28 axes[1].set_title('有无污染的二项Logistic回归的分类边界', fontsize = 14)
29 axes[1].set_xlabel('PM2.5', fontsize = 14)
30 axes[1].set_ylabel('PM10', fontsize = 14)
31 axes[1].legend()
32 print('总错判率:%f'%(1-modelLR.score(X, y)))
```

- 问：
 - 如何认识两颜色区域的边界
 - 分类边界
 - 这里的分类边界有什么特点？
 - 分类边界的方程？



$$\text{Logit } P = -4.85 + 0.05PM2.5 + 0.02PM10$$

$$-4.85 + 0.05PM2.5 + 0.02PM10 = 0$$



- 问：


- 分类边界在预测中有什么用途？以案例三为例



$$\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

$$\text{Logit } P = -4.85 + 0.05PM2.5 + 0.02PM10$$

$$-4.85 + 0.05PM2.5 + 0.02PM10 = 0$$



- y^* 可以表征什么？与概率的关系？
- 如果再引入SO2，两类的边界会是怎样的？
 - 分类边界方程？

$$\hat{\beta}_0 + \hat{\beta}_1 PM2.5 + \hat{\beta}_2 PM10 + \hat{\beta}_3 SO2 = 0$$

- 案例三模型还可以优化吗？ 总错判率：0.153149

• 案例三的分析：改进的二项Logistic回归模型

$$\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 PM2.5 + \beta_2 PM10 + \beta_3 SO_2 + \beta_4 CO + \beta_5 NO_2 + \beta_6 O_3 + u$$

```
1 X1 = data[['PM2.5', 'PM10', 'SO2', 'CO', 'NO2', 'O3']]
2 y = data['有无污染']
3 modelLR1 = LM.LogisticRegression()
4 modelLR1.fit(X1, y)
5 print('混淆矩阵:\n', confusion_matrix(y, modelLR1.predict(X1)))
6 print('总正确率', accuracy_score(y, modelLR1.predict(X1)))
7 print('总错判率:', 1-modelLR1.score(X1, y))
8 print('F1-score:', f1_score(y, modelLR1.predict(X1), pos_label=1))
```

实际↔ 类别值↔	预测类别值↔	
	1↔	0↔
1↔	TP↔	FN↔
0↔	FP↔	TN↔

混淆矩阵：
[[1128 76]
[88 804]]
总正确率 0.9217557251908397
总错判率：0.0782442748091603
F1-score: 0.90744920993228

• 问：

• 为什么改进模型的总错判率低于之前的模型？

• 得到什么启示？

总错判率:0.153149

• 你认为改进模型全面优于之前的模型吗？

• 如何理解全面优于？概率阈值

改进模型的预测误差较低，比较理想!


更全面地评价分类预测模型：图形化评价工具

- ROC曲线：纵坐标为TPR，横坐标为FPR
 - 按预测概率降序排序
 - 取分位点上的概率值作为判断1/0的阈值
 - 计算TPR和FPR，画点，点连线


实际 类别值	预测类别值	
	1	0
1	TP	FN
0	FP	TN

AUC值

概率	实际值	TPR	FPR
0.65	1	1/5	0/4
0.63	1	2/5	0/4
0.62	1	3/5	0/4
0.61	1	4/5	0/4
0.58	0	4/5	1/4
0.56	0	4/5	2/4
0.55	1	5/5	2/4
0.54	0	5/5	3/4
0.51	0	5/5	4/4



(a) ROC 曲线与 AUC



(b) 基于有限样例绘制的 ROC 曲线与 AUC



• 案例三的分析：ROC曲线和AUC值；PR曲线

```

9 fpr1, tpr1, thresholds1 = roc_curve(y, modelLR1.predict_proba(X1)[: ,1], pos_label=1)
10 fpr, tpr, thresholds = roc_curve(y, modelLR.predict_proba(X)[: ,1], pos_label=1)
11 fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(15, 6), dpi=150)
12 axes[0].plot(fpr1, tpr1, color='r', linewidth=2, label='示例2的ROC curve (area = %0.5f)' % auc(fpr1, tpr1))
13 axes[0].plot(fpr, tpr, color='g', linewidth=2, linestyle='--', label='示例1的ROC curve (area = %0.5f)' % auc(fpr, tpr))
14 axes[0].plot([0, 1], [0, 1], color='blue', linestyle='dashed', linewidth=2)
15 axes[0].set_xlim([0, 1])
16 axes[0].set_ylim([0, 1])
17 axes[0].set_title('ROC曲线')
18 axes[0].set_xlabel('FPR')
19 axes[0].set_ylabel('TPR')
20 axes[0].legend(loc='best')
21 pre1, rec1, thresholds1 = precision_recall_curve(y1, modelLR1.predict_proba(X1)[: ,1])
22 pre, rec, thresholds = precision_recall_curve(y, modelLR.predict_proba(X)[: ,1])
23 axes[1].plot(rec1, pre1, color='r', linewidth=2, label='示例2的PR curve (area = %0.5f)' % auc(rec1, pre1))
24 axes[1].plot(rec, pre, color='g', linewidth=2, linestyle='--', label='示例1的PR curve (area = %0.5f)' % auc(rec, pre))
25 axes[1].plot([0, 1], [0, 1], color='blue', linestyle='dashed', linewidth=2)
26 axes[1].set_xlim([0, 1])
27 axes[1].set_ylim([0, 1])
28 axes[1].set_title('PR曲线')
29 axes[1].set_xlabel('查全率R')
30 axes[1].set_ylabel('查准率P')
31 axes[1].legend(loc='best')

```


chapter3-3.ipynb



• 问：

- 改进模型 **全面优于** 之前的模型吗？为什么？
- ROC曲线还有其他用途吗？
- 问：如何解决案例三的多分类预测问题？

质量等级	数量
良	827
轻度污染	470
优	377
中度污染	252
重度污染	127
严重污染	43



(b) 基于有限样例绘制的 ROC 曲线与 AUC

多分类预测中的经典统计方法

- 多分类(K)预测模型的一般处理策略
 - 1对1 (one-versus-one) 策略：令第 k 类为一类(记为1)，其余类依次作为另一类(记为0)，分别构建 $M = \binom{K}{2}$ 个二分类预测模型
 - 1对多 (one-versus-all) 策略：令第 k 类为一类(记为1)，其余 $K - 1$ 个类别都归为另一类(记为0)，分别构建 $M = K$ 个二分类预测模型
 - 由 M 个二分类模型通过投票方式共同参与分类预测

→AQI是空气质量指数 (Air Quality Index) 的简称，是新环境空气质量标准用于描述空气质量状况的指标。

空气质量指数 (AQI)

AQI 值	AQI 分类	AQI 颜色
0 - 50	优	绿色
51 - 100	良	黄色
101 - 150	轻度污染	橙色
151 - 200	中度污染	红色
201 - 300	重度污染	紫色
301 - 500	严重污染	褐红色

→按照AQI的数值大小将空气质量状况分成了优、良、轻度污染、中度污染、重污染、严重污染六个等级。

多分类预测中的经典统计方法

- Softmax回归：多(K)分类预测模型
 - 一般采用1对多策略，通过建立 K 个Logistic回归模型实现 K 分类的预测

$$\begin{aligned}\log\left(\frac{P_1}{1-P_1}\right) &= \beta_0^1 + \beta_1^1 X_1 + \beta_2^1 X_2 + \cdots + \beta_p^1 X_p + \varepsilon_1 = f_1(\mathbf{X}) + \varepsilon_1 \\ \log\left(\frac{P_2}{1-P_2}\right) &= \beta_0^2 + \beta_1^2 X_1 + \beta_2^2 X_2 + \cdots + \beta_p^2 X_p + \varepsilon_2 = f_2(\mathbf{X}) + \varepsilon_2 \\ &\dots\dots \\ \log\left(\frac{P_K}{1-P_K}\right) &= \beta_0^K + \beta_1^K X_1 + \beta_2^K X_2 + \cdots + \beta_p^K X_p + \varepsilon_K = f_K(\mathbf{X}) + \varepsilon_K\end{aligned}$$

$$P_k = \frac{\exp(f_k)}{\sum_{j=1}^K \exp(f_j)} \Rightarrow \sum_{k=1}^K P_k = 1 \quad \frac{\exp(f_k)}{\sum_{j=1}^K \exp(f_j)} \quad \text{称为Softmax函数，得名Softmax回归}$$

案例三的分析：空气质量等级的多分类预测

softmax回归模型

chapter3-3.ipynb

```
1 X = data[['PM2.5', 'PM10', 'SO2', 'CO', 'NO2', 'O3']]
2 y = data['质量等级']
3 modelLR2 = LM.LogisticRegression(multi_class='multinomial')
4 modelLR2.fit(X, y)
5 print('总正确率', accuracy_score(y, modelLR2.predict(X)))
6 print('评价模型结果:\n', classification_report(y, modelLR2.predict(X)))
```

总正确率 0.5734732824427481

评价模型结果：

	precision	recall	f1-score	support
严重污染	0.69	0.67	0.68	43
中度污染	0.48	0.35	0.41	252
优	0.68	0.55	0.61	377
良	0.61	0.70	0.65	827
轻度污染	0.43	0.44	0.44	470
重度污染	0.65	0.69	0.67	127
accuracy			0.57	2096
macro avg	0.59	0.57	0.58	2096
weighted avg	0.57	0.57	0.57	2096

问：

- 除计算总正确率之外，多分类预测中还需关注什么？
 - 混淆矩阵和混淆矩阵的可视化
 - 对各小类的评价指标

混淆矩阵：

```
[[ 29  0  0  0  0 14]
 [ 1 89  0 29 106 27]
 [ 0  0 207 163  7  0]
 [ 0 16 83 580 148  0]
 [ 1 67 14 172 209  7]
 [11 12  0  3 13 88]]
```

```
1 print('混淆矩阵:\n', confusion_matrix(y, modelLR2.predict(X)))
2 plt.figure(dpi=150, figsize=(4, 2))
3 sns.heatmap(confusion_matrix(y, modelLR2.predict(X), normalize='true'), annot=True, fmt='.2f',
4 plt.title('混淆矩阵', fontsize=6))
```



- 问：如何进一步评价多分类预测模型的**整体**预测效果？

- 宏平均 (Macro-averaged) 意义和微平均 (Micro-averaged) 意义下的评价指标

- 案例三宏平均指标的Python计算

```
print('评价模型结果：\n', classification_report(y, modelLR2.predict(X)))
```

- 例如：下表中的宏平均指标(如recall)

		预测类别			合计	召回率
		A	B	C		
实际类别	A	90			100	0.9
	B		5		10	0.5
	C			1	10	0.1

计算平均值： $(0.9 + 0.5 + 0.1) \div 3 = 0.5$

总正确率 0.5734732824427481

评价模型结果：

	precision	recall	f1-score	support
严重污染	0.69	0.67	0.68	43
中度污染	0.48	0.35	0.41	252
优	0.68	0.55	0.61	377
良	0.61	0.70	0.65	827
轻度污染	0.43	0.44	0.44	470
重度污染	0.65	0.69	0.67	127
accuracy			0.57	2096
macro avg	0.59	0.57	0.58	2096
weighted avg	0.57	0.57	0.57	2096

- 宏平均指标的特点：

- 平等对待每个**类别**
- 受**小类**影响(如类C的召回率仅0.1，显著**拉低**宏平均)

- 问：为什么小类的评价指标一般较低？如何消除拉低的影响？

- 问：宏平均指标的适用场景？

- 每个类别都同等重要
- 数据存在严重不平衡时希望评价结果可体现模型在少数类上的表现


- 问：如何评价多分类预测模型的**整体**预测效果？
 - **宏平均** (Macro-averaged) 意义和**微平均** (Micro-averaged) 意义下的评价指标
 - 微平均指标的计算：
 - 混淆矩阵**汇总** (把所有类别的样本放在一起) → 再算评价指标
 - 例如：下表中的微平均指标(如recall)

		预测类别			合计	召回率
		A	B	C		
实际类别	A	90			100	0.9
	B		5		10	0.5
	C			1	10	0.1

$$\text{全局召回率} = \text{总TP} / (\text{总TP} + \text{总FN}) = 96 / (96 + 24) = 0.8$$

- 微平均指标的特点：
 - 平等对待每个**样本观测**
 - 受**大类**影响(如大类A贡献90个正确样本，B和C加起来只贡献6个)
 - 微平均分数(0.8)接近于大类A的分数(0.9)，掩盖了小类(如C 0.1)的糟糕表现
- 问：微平均指标的适用场景？
 - 每个样本都同等重要
 - 关注对样本整体(大多数)的分类预测效果，忽略某个小类的错判

- 问：如何使案例三的预测误差更低？
 - 不确定经典统计分类模型假定是否合理时：
 - 机器学习可以做得更好！
 - 从直线到曲线，从平面到曲面
- 机器学习可以有效提高分类预测精度



- 机器学习可以高效解决非线性分类问题

混淆矩阵：

$\begin{bmatrix} 1128 & 76 \\ 88 & 804 \end{bmatrix}$

总正确率 0.9217557251908397


总错判率：0.0782442748091603

F1-score: 0.90744920993228

总正确率 0.5734732824427481



评价模型结果：

	precision	recall	f1-score	support
严重污染	0.69	0.67	0.68	43
中度污染	0.48	0.35	0.41	252
优	0.68	0.55	0.61	377
良	0.61	0.70	0.65	827
轻度污染	0.43	0.44	0.44	470
重度污染	0.65	0.69	0.67	127
accuracy			0.57	2096
macro avg	0.59	0.57	0.58	2096
weighted avg	0.57	0.57	0.57	2096






问题3：经典统计方法与机器学习算法的互补性

- 总结：无论是回归预测还是分类预测
 - 经典统计方法：在可解释性上优势明显---基于线性模型假设；假设不满足时模型预测精度不高；无法有效解决非线性预测问题
 - 机器学习算法：解决非线性回归和非线性分类问题上有独特优势



问题4：经典统计方法与机器学习的共通处

■ 以回归预测为例




$$Y = f(X) + \epsilon.$$

- f 是 $\mathbf{X}$ 对 y 的系统性信息 (未知)
- $E(\epsilon) = 0$ 独立于 $\mathbf{X}$

■ 问：

- 回归预测的核心任务？估计 f
 - 对比经典统计方法和机器学习



■ 对比经典统计方法和机器学习：以回归预测为例



• 经典统计方法(线性回归)

• 线性模型假设

$$\hat{f}(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$



- 通过某种策略估计未知参数 $\beta_1, \dots, \beta_p$ ，找到预测效果最理想下的模型参数 $\hat{\beta}_1, \dots, \hat{\beta}_p$

• 机器学习算法

- 不做线性模型假设
- 通过某些搜索算法找到预测效果最理想下的模型参数


■ 两者的共通处：均涉及损失函数

■ 问：

- 什么是损失函数？
- 损失函数的作用是什么？

- 问：什么是损失函数？ 便于理解，先看经典统计中的一般线性回归模型
- 问：可通过什么策略估计回归预测模型中的未知参数 β

$$y = \beta_0 + \beta_1 X_1 \quad \sum_{i=1}^N \left(y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_{i1}) \right)^2$$



- 基于策略得到的参数估计结果称为一般线性回归模型的最小二乘估计

$$\text{• 若: } \sum_{i=1}^N \left(y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_{i1}) \right)^2 = \sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N L(y_i, f(X_i; \hat{\beta}))$$

- 称 L 为损失函数，这里是关于模型参数的二次函数(非负)

- 可见，回归预测中损失函数 L :

- 是误差 e 的函数， e 称为残差： $e_i = y_i - \hat{y}_i (i = 1, 2, \dots, N)$

- 是平方损失函数： $L(e) = L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$

$$\text{• 总损失: } \sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

- 问：

- 谁是构成损失函数中不可或缺的“成员”？

- y

- 问：损失函数的作用？ 便于理解，先看经典统计中的一般线性回归模型

- 测度预测效果(误差)，指导或称监督建模

- 要找到损失函数最小下的模型参数 $\hat{\beta}$

$$\sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$\sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N \left(y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \hat{\beta}_2 X_{i2} + \cdots + \hat{\beta}_p X_{ip}) \right)^2$$

- 称其属于有监督学习的范畴

- 问：谁在监督？如何参与监督(最小二乘估计的参数求解)？

$$\begin{cases} \frac{\partial L}{\partial \beta_0} \big|_{\beta_0=\hat{\beta}_0} = -2 \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{i1} - \hat{\beta}_2 X_{i2} - \cdots - \hat{\beta}_p X_{ip}) = 0 \\ \frac{\partial L}{\partial \beta_1} \big|_{\beta_1=\hat{\beta}_1} = -2 \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{i1} - \hat{\beta}_2 X_{i2} - \cdots - \hat{\beta}_p X_{ip}) X_{i1} = 0 \\ \frac{\partial L}{\partial \beta_2} \big|_{\beta_2=\hat{\beta}_2} = -2 \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{i1} - \hat{\beta}_2 X_{i2} - \cdots - \hat{\beta}_p X_{ip}) X_{i2} = 0 \\ \dots \dots \\ \frac{\partial L}{\partial \beta_p} \big|_{\beta_p=\hat{\beta}_p} = -2 \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{i1} - \hat{\beta}_2 X_{i2} - \cdots - \hat{\beta}_p X_{ip}) X_{ip} = 0 \end{cases}$$

- 要求：

- y_i 的取值已知！
- 线性模型假设
- $N \geq p + 1$



- 问：

- 机器学习中不作线性模型假设，损失函数如何监督建模？

- 问：机器学习中不作线性模型假设，损失函数如何监督建模？

$$\sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N L(y_i, \hat{f}(X_i))$$

- 因 $\hat{f}$ 可能是任意复杂形式，故损失函数 L 也会是任意复杂形式
 - 不再是模型参数(可记为 β 或 w)的二次函数形式



- 问：
 - 如何理解这个曲面？
 - 损失函数
 - 如何找到曲面取最小时的点(C点)？
 - 需一定的优化搜索策略
 - 如梯度下降法

- 参数估计的梯度下降法:通过迭代, 利用关于 L 曲率的局部信息, 引导在 L 曲面上进行局部搜索

- 例: 函数 $L(w) = w^2 + 1$, 要求 $L(w)$ 最小时 w 的值

- $w(t+1) = w(t) + \Delta w = w(t) - \rho \left[\frac{\partial L(w)}{\partial w} \right]_{w=w(t)}$



- ρ 称为**学习率**

- $w(0)=4, \rho = 0.1; \left[\frac{\partial L(w)}{\partial w} \right]_{w=4} = 8 > 0$

$$w(1) = 4 - 0.1 \times (2 \times 4) = 3.2$$

$$w(2) = 3.2 - 0.1 \times (2 \times 3.2) = 2.56$$


$$w(3) = 2.56 - 0.1 \times (2 \times 2.56) = 2.04$$



```
1  ##简单的梯度下降法
2  w = 4
3  rho = 0.1
4  for i in np.arange(1,20):
5      w = w - rho * (2 * w)
6      print('第%d次迭代: w=%.5f, 函数值=%.5f' % (i, w, w**2+1))
```

第1次迭代: w=3.20000, 函数值=11.24000
 第2次迭代: w=2.56000, 函数值=7.55360
 第3次迭代: w=2.04800, 函数值=5.19430
 第4次迭代: w=1.63840, 函数值=3.68435
 第5次迭代: w=1.31072, 函数值=2.71799
 第6次迭代: w=1.04858, 函数值=2.09951
 第7次迭代: w=0.83886, 函数值=1.70369
 第8次迭代: w=0.67109, 函数值=1.45036
 第9次迭代: w=0.53687, 函数值=1.28823
 第10次迭代: w=0.42950, 函数值=1.18447
 第11次迭代: w=0.34360, 函数值=1.11806
 第12次迭代: w=0.27488, 函数值=1.07556
 第13次迭代: w=0.21990, 函数值=1.04836
 第14次迭代: w=0.17592, 函数值=1.03095
 第15次迭代: w=0.14074, 函数值=1.01981
 第16次迭代: w=0.11259, 函数值=1.01268
 第17次迭代: w=0.09007, 函数值=1.00811
 第18次迭代: w=0.07206, 函数值=1.00519
 第19次迭代: w=0.05765, 函数值=1.00332

- 问: 如何能够减少迭代次数?
 学习率 ρ 会影响 Δw , 不可太大或太小



- 问：分类预测中损失函数？ y 是如何履行监督职责的？

- 分类预测中的交叉熵损失：

$$\hat{P}_k(\mathbf{X}_i) = \hat{P}(\hat{y}_i = k | \mathbf{X}_i)$$

$$L(y_i, \hat{P}_k(\mathbf{X}_i)) = - \sum_{k=1}^K I(y_i = k) \log(\hat{P}_k(\mathbf{X}_i)) = -\log \hat{P}_{y_i}(\mathbf{X}_i)$$

- 问：

- 交叉熵损失是正是负？
- 负号的作用？

- 二项偏差损失函数($y_i = 0/1$): $\hat{P}(\mathbf{X}_i) = \hat{P}(\hat{y}_i = 1 | \mathbf{X}_i)$

$$L(y_i, \hat{P}(\mathbf{X}_i)) = -[y_i \log \hat{P}(\mathbf{X}_i) + (1 - y_i) \log(1 - \hat{P}(\mathbf{X}_i))]$$

- Logistic回归的损失函数

$$\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

$$\hat{P}(\mathbf{X}_i) = \frac{1}{1 + \exp(-\hat{f}(\mathbf{X}_i))} \quad -y_i \log \frac{\exp(f(\mathbf{X}_i))}{1 + \exp(f(\mathbf{X}_i))} - (1 - y_i) \log \frac{1}{1 + \exp(f(\mathbf{X}_i))}$$

$$L(y_i, \hat{f}(\mathbf{X}_i)) = -y_i \hat{f}(\mathbf{X}_i) + \log(1 + \exp(\hat{f}(\mathbf{X}_i)))$$

- 有能力同学可追问：

- Logistic的损失函数与其对数似然函数的关系？ $L_i = P^{y_i}(1 - P)^{(1-y_i)}$

- 有能力的同学可延展，进一步体会 y 是如何履行监督职责的
 - Logistic回归模型参数的梯度下降法估计

■ 损失函数：
$$\log\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

$$L(y_i, \hat{P}(\mathbf{X}_i)) = -[y_i \log \hat{P}(\mathbf{X}_i) + (1 - y_i) \log(1 - \hat{P}(\mathbf{X}_i))]$$

$$L(y_i, \hat{f}(\mathbf{X}_i)) = -y_i \hat{f}(\mathbf{X}_i) + \log(1 + \exp(\hat{f}(\mathbf{X}_i)))$$

- 依据梯度下降法，有：

$$w(t+1) = w(t) + \Delta w = w(t) - \rho \left[\frac{\partial L(w)}{\partial w} \right]_{w=w(t)}$$

■ $\beta_j(t+1) = \beta_j(t) + \Delta \beta_j$

■
$$\Delta \beta_j = -\rho \sum_{i=1}^N \left[\frac{\exp(\hat{f}(\mathbf{X}_i))}{1 + \exp(\hat{f}(\mathbf{X}_i))} (t) - y_i \right] x_{ij} = -\rho \sum_{i=1}^N [\hat{P}(\mathbf{X}_i)(t) - y_i] x_{ij}$$

• 问：

- $K(K > 2)$ 多分类Softmax回归的损失函数？

$$L(y_i, \hat{P}_k(\mathbf{X}_i)) = - \sum_{k=1}^K I(y_i = k) \log(\hat{P}_k(\mathbf{X}_i)) = -\log \hat{P}_{y_i}(\mathbf{X}_i)$$



$$L(y_i, \hat{P}_{y_i}(\mathbf{X}_i)) = - \sum_{k=1}^K I(y_i = k) \log \left(\frac{\exp(\hat{f}_k(\mathbf{X}_i))}{\sum_{j=1}^K \exp(\hat{f}_j(\mathbf{X}_i))} \right) = -\log \left(\frac{\exp(\hat{f}_{y_i}(\mathbf{X}_i))}{\sum_{j=1}^K \exp(\hat{f}_j(\mathbf{X}_i))} \right)$$

问题5：本课程关注机器学习的哪些方面


- 关注：机器学习探索和归纳数据间非线性关系的策略？
 - 从经典统计的模型驱动→通过各种算法实现数据驱动的归纳式探索
- 问：
 - 什么是算法？

■ 算法：一般指计算机中解决某个问题的一系列清晰指令的集合。如：

■ 排序算法 (交换排序【冒泡法、快速排序】、插入排序【直接法、希尔排序】、选择排序等)


■ PageRank算法

- PageRank算法是图的链接分析(link analysis)的代表性算法，提出时服务于Google搜索引擎排序
- 定义在有向图上的随机游走过程，迭代算法
 - 如果指向A网页的超链接越多，随机跳转到A网页的概率就越高，A网页的PageRank值就越高，A网页越重要
 - 如果指向A网页的多个网页的PageRank值越高，A网页的PageRank值就越高，A网页越重要
- PageRank可以定义在任意有向图上，后来被应用到社会影响力分析、文本摘要等多个方面



■ HITS (Hypertext-Induced Topic Search) 算法

- 利用网页内容权威值(Authority)和链接枢纽值(Hub)对网页评估(学术文献评价)
- 迭代算法
 - 权威值：所有导入链接所在页面的枢纽值之和；
 - 枢纽值：页面上所有链接指向页面的权威值之和



■ 协同过滤算法

- 推荐算法，基于用户的协同过滤和基于商品的协同过滤，等

■ 机器学习算法一般指以什么策略(怎么做)在数据中找规则

- 涉及数学和优化方法等
- 本课程只要求掌握算法的设计思路

问题5：本课程关注机器学习的哪些方面

- 关注：机器学习探索和归纳数据间非线性关系的策略？
 - 从统计的模型驱动→通过各种算法实现数据驱动的归纳式探索
- 问：
 - 归纳式探索的角度？
 - 取决于如何看待曲线(曲面)
 - 曲面由许多局部平面平滑连接的结果
 - 是高维 G 空间 $\mathbb{R}^G$ 中平面在 $I(G > I)$ 维空间 $\mathbb{R}^I$ 中的一种呈现



机器学习 第一次作业

• 案例数据分析(1):

- 将整理好的学生成绩数据保存为ReportCard.csv文件(如下), 后续对ReportCard.csv分析

```
1 data=pd.read_csv("ReportCard.csv") #以逗号分隔
2 data.head(10)
```

	xh	sex	poli	chi	math	fore	phy	che	geo	his	zf	pjf	fz	xb1	xb2
0	92103	2.0	NaN	NaN	NaN	66.0	98.0	79.0	89.0	81.0	413.0	82.6	良	0	1
1	92239	2.0	40.0	63.0	44.0	21.0	54.0	26.0	26.0	55.0	329.0	41.1	不及格	0	1

```
2 92142
3 92223
4 92144
5 92217
6 92111
7 92146
1 #数据预先处理
2 fill_value=data.iloc[:,2:10].apply(lambda x: round(x.mean(),2))
3 print(fill_value)
4 data=data.fillna(fill_value)
5 data['zf']=data.iloc[:,2:10].sum(axis=1) #axis=0, 以变量为对象计算
6 data['pjf']=np.round(data.loc[:, 'poli': 'his'].mean(axis=1),1)
7 bins=[0,59.9,69.9,79.9,89.9,100]
8 data['fz']=pd.cut(data['pjf'],bins,labels=['不及格','及格','中','良','优'])
9 data.iloc[0:5,]
```

```
8 92234 poli 79.64
9 92113 chi 83.28
math 61.17
fore 49.92
phy 75.20
che 54.08
geo 65.24
his 78.68
dtype: float64
```

	xh	sex	poli	chi	math	fore	phy	che	geo	his	zf	pjf	fz	xb1	xb2
0	92103	2.0	79.64	83.28	61.17	66.0	98.0	79.0	89.0	81.0	637.09	79.6	中	0	1
1	92239	2.0	40.00	63.00	44.00	21.0	54.0	26.0	26.0	55.0	329.00	41.1	不及格	0	1
2	92142	2.0	79.64	70.00	59.00	22.0	68.0	26.0	26.0	63.0	413.64	51.7	不及格	0	1
3	92223	1.0	56.00	91.00	65.50	68.0	77.0	39.0	54.5	63.0	514.00	64.2	及格	1	0
4	92144	1.0	59.00	79.00	34.00	34.0	57.0	37.0	37.0	76.0	413.00	51.6	不及格	1	0

• 案例数据分析(1):

- 将整理好的学生成绩数据ReportCard.csv文件(如下), 进行以下分析

	xh	sex	poli	chi	math	fore	phy	che	geo	his	zf	pjf	fz	xb1	xb2
0	92103	2.0	79.64	83.28	61.17	66.0	98.0	79.0	89.0	81.0	637.09	79.6	中	0	1
1	92239	2.0	40.00	63.00	44.00	21.0	54.0	26.0	26.0	55.0	329.00	41.1	不及格	0	1
2	92142	2.0	79.64	70.00	59.00	22.0	68.0	26.0	26.0	63.0	413.64	51.7	不及格	0	1
3	92223	1.0	56.00	91.00	65.50	68.0	77.0	39.0	54.5	63.0	514.00	64.2	及格	1	0
4	92144	1.0	59.00	79.00	34.00	34.0	57.0	37.0	37.0	76.0	413.00	51.6	不及格	1	0

- 请利用一元线性回归模型分析并说明选择该模型的合理性
 - 数学成绩(math)的提高对总成绩有怎样的影响?
 - 语文成绩(chi)的提高对总成绩有怎样的影响?
- 请利用二元线性回归模型分析数学和语文成绩的提高对总成绩的影响
 - 与一元回归模型相比, 二元回归模型的MSE是否减少了? 为什么会减少呢?
 - `from sklearn.metrics import mean_squared_error`
 - `mean_squared_error(y,modelLR.predict(X))`
 - 与一元回归模型相比, 说明为什么两者对总成绩的影响结果出现了差异?
 - 分析数学成绩和语文成绩, 哪个对总成绩有更大的影响
- 在相等的数学成绩以及相等的语文成绩条件下, 男生和女生的总成绩有怎样的差异?

如何理解题意?

- 案例数据分析(2):

- 有人认为，从大数据研究角度看，社会文化及生理发育等因素的差异，会导致教育产生群体性影响，表现出不同性别学生的学习成绩差异较大。
- 请问：学生成绩数据ReportCard.csv文件(如下)是否支持上述观点？为什么？

	xh	sex	poli	chi	math	fore	phy	che	geo	his	zf	pjf	fz	xb1	xb2
0	92103	2.0	79.64	83.28	61.17	66.0	98.0	79.0	89.0	81.0	637.09	79.6	中	0	1
1	92239	2.0	40.00	63.00	44.00	21.0	54.0	26.0	26.0	55.0	329.00	41.1	不及格	0	1
2	92142	2.0	79.64	70.00	59.00	22.0	68.0	26.0	26.0	63.0	413.64	51.7	不及格	0	1
3	92223	1.0	56.00	91.00	65.50	68.0	77.0	39.0	54.5	63.0	514.00	64.2	及格	1	0
4	92144	1.0	59.00	79.00	34.00	34.0	57.0	37.0	37.0	76.0	413.00	51.6	不及格	1	0

作业提交要求

- 作业提交截止时间：3月XX日24:00
- 作业提交邮箱：stat14@126.com
- 文件命名示例：2024001张三(1).PDF
 - 在 Jupyter Notebook环境下按Ctrl+P→另存为PDF
 - 须包括：答题文字 + Python代码 + 运行结果

选择建立一元线性回归模型，原因：XXX……。由模型结果可知数学成绩每提高1分，将使总分的均值提高3.9分。XXX……。具体代码和运行结果如下。

```
2 X=data[['math']]
3 y=data['zf']
4 modelLR.fit(X,y)
5 print('一元(math)回归模型:\n回归系数=%s:MSE=%f'%(modelLR.coef_,mean_squared_error(y,modelLR.predict(X))))
```

一元(math)回归模型：

回归系数=[3.96119389] ;MSE=2110.231746