


第四讲 最具稳健性的机器学习预测算法 ---支持向量机

主要内容

- 讨论案例六的分类预测问题
 - 案例的特点
 - 案例的多分类预测模型构建
 - 支持向量分类的基本思想
 - 理想情况下的分类预测：完全线性可分下的支持向量分类
 - 案例的不断探索
 - 现实情况下的分类预测：广义线性可分下的支持向量分类
 - 复杂情况下的分类预测：线性不可分下的支持向量分类
 - 基于数据对模型做进一步探索
- 支持向量机算法思考

案例六：老年人危险体位预警

• 案例六简介



- 正方性表示无线穿戴设备
- 从平躺在床上，到坐起、起身站起、直立及行走过程中的体位 (Activity) 变化
- 随体位实时变化 (TimeStamp, 不同时间点)，无线穿戴设备的竖直高度 (vertical, 设备距地面的高度)、水平位置 (frontal, lateral, 设备距两个垂直墙体的距离) 数据以及倾角 (Phase) 等都会发生变化
- 数据通过房间内的3个射频识别 (Radio Frequency Identification, RFID) 设备实时采集并传回
 - 其中，2个RFID安装在天花板上，1个安装在墙上
- 老人在室内走动时各设备 (SensorID) 采集的信号强度 (RSSI) 会不同
- 数据采集时段内 (样本量22646)，老人们的体位状态包括
 - 1：坐在床上；2：坐在椅子上；3：躺在床上；4：站立或行走

案例六：老年人危险体位预警

案例六简介

```
1 path = './健康物联网/'
2 filenames = os.listdir(path = path)
3 data = pd.DataFrame(columns = ['TimeStamp', 'frontal', 'vertical', 'lateral',
4                               'SensorID', 'RSSI', 'Phase', 'Frequency', 'Activity', 'ID', 'Gender'])
5 i = 1
6 for filename in filenames:
7     tmp = pd.read_csv(path + filename)
8     tmp['ID'] = i
9     tmp['Gender'] = filename[-5]
10    i += 1
11    data = data.append(tmp)
12 data.head(5)
```


```
['d2p01F.csv', 'd2p02F.csv', 'd2p03F.csv', 'd2p04F.csv', 'd2p05F.csv', 'd2p06F.csv', 'd2p07F.csv', 'd2p08F.csv', 'd2p09F.csv',
'd2p10F.csv', 'd2p11F.csv', 'd2p12F.csv', 'd2p13F.csv', 'd2p14F.csv', 'd2p15F.csv', 'd2p16F.csv', 'd2p17F.csv', 'd2p18M.csv',
'd2p19M.csv', 'd2p20M.csv', 'd2p21M.csv', 'd2p22M.csv', 'd2p23F.csv', 'd2p24F.csv', 'd2p25F.csv', 'd2p26F.csv', 'd2p27F.csv']
```

	TimeStamp	frontal	vertical	lateral	SensorID	RSSI	Phase	Frequency	Activity	ID	Gender
0	0.00	-0.232160	0.215880	-1.18820	2	-48.5	2.74430	920.75	3	1	F
1	0.25	-0.056282	0.043636	-1.14260	2	-50.0	2.36540	921.75	3	1	F
2	0.50	0.143050	0.296270	-1.33640	3	-59.5	0.20709	922.25	3	1	F
3	0.75	0.318930	0.284780	-0.92593	2	-51.0	0.41571	923.25	3	1	F
4	1.05	0.412730	0.135500	-1.02860	2	-44.5	4.45470	920.25	3	1	F

d2p01F
d2p02F
d2p03F
d2p04F
d2p05F
d2p06F
d2p07F
d2p08F
d2p09F
d2p10F
d2p11F
d2p12F
d2p13F
d2p14F
d2p15F
d2p16F
d2p17F
d2p18M
d2p19M
d2p20M
d2p21M
d2p22M
d2p23F
d2p24F
d2p25F
d2p26F
d2p27F

案例六：老年人危险体位预警


案例六简介



特点：


- 多分类预测
- 类别分布差异较大
- 案例特点：高置信度、高稳健性的预测

二维空间的展示




支持向量机


- **支持向量机**（Support Vector Machine, SVM）是在统计学习理论（Statistical Learning Theory, SLT）基础上发展起来的一种机器学习方法（1992年由 Boser, Guyon和 Vapnik 提出）
 - 在解决**小样本**、**非线性**和**高维**的分类预测和回归预测问题上有许多优势
 - 支持向量机可实现**分类**预测和**回归**预测(略)
- 支持向量分类的目的：
 - 基于训练集，在 p 维(输入变量个数)空间中找到能将两类(+1, -1)样本有效分开的分类超平面：如： $b + w_1X_1 + w_2X_2 = 0$
 - **预测**： $b + \mathbf{w}^T \mathbf{X} = 0 \Rightarrow \hat{b} + \hat{\mathbf{w}}^T \mathbf{X} = 0$
 - $\hat{b} + \hat{\mathbf{w}}^T \mathbf{X}_i > 0$ 的样本观测（位于超平面的一侧），输出变量 $\hat{y}_i = 1$ ，且希望 $\hat{y}_i = y_i$
 - $\hat{b} + \hat{\mathbf{w}}^T \mathbf{X}_i < 0$ 的样本观测（位于超平面的另一侧），输出变量 $\hat{y}_i = -1$ ，且希望 $\hat{y}_i = y_i$



- 支持向量分类的基本思路：
 - 可能会找到多个能将两类样本观测点分开的分类超平面
 - 固定迭代次数下，不同初始参数的神经网络给出分类边界
 - 应采用哪个超平面进行预测呢？
- 支持向量分类给出的分类超平面：具有**最大边界的超平面(决策边界)**：距两类别的边缘观测点最远的超平面






落在平行边界上的样本观测点称为**支持向量**




- 问：
 - 基于最大边界超平面进行分类预测有什么优势？
 - 置信度
 - 稳定性(鲁棒性)

- 支持向量分类的基本思路：
 - 可能会找到多个能将两类样本观测点分开的分类超平面
- 分类的三种场景
 - **线性可分样本**：样本观测点可被超平面线性分开的情况
 - **完全线性可分**
 - 样本无法完全线性可分：**广义线性可分**
 - **线性不可分样本**



完全线性可分下的支持向量分类：理想

- 问：如何实现？以二维空间为例




所有样本观测点均在平行边界的外侧

- 找到：
 - 相距最远的一对平行边界(间隔)
 - 最大边界超平面(线)是平行边界的中间平行线
- 问：支持向量机关注什么？
 - d 最远
 - 能将两类正确分类
- 如何转化为一个数学问题？

完全线性可分下的支持向量分类：理想

- d 的数学表达

- 记 $y_i = 1$ 类的边界直线(其上样本观测点记为 X^+)方程为：
 - $b + \mathbf{w}^T \mathbf{X}^+ = 1$, 如: $b + w_1 X_1^+ + w_2 X_2^+ = 1$
- 因超平面方程为: $b + \mathbf{w}^T \mathbf{X} = 0$, 则:
 - $y_i = -1$ 类的边界直线(其上样本观测点记为 X^-)方程为:
 - $b + \mathbf{w}^T \mathbf{X}^- = -1$, 如: $b + w_1 X_1^- + w_2 X_2^- = -1$



- d 的数学表达：两平行线间的距离

$$Ax + By + C1 = 0 \text{ 和 } Ax + By + C2 = 0$$

$$d = |C1 - C2| / \sqrt{A^2 + B^2}$$

- 两平行直线间的距离为: $\lambda = \frac{2}{\|\mathbf{w}\|}$, $\|\mathbf{w}\| = \sqrt{\mathbf{w}^T \mathbf{w}}$

- $d = \frac{1}{\|\mathbf{w}\|}$

- 目标：找到 d 最大的一对平行边界

完全线性可分下的支持向量分类：理想

- 能正确分类的数学表达：几何角度的考虑
 - 要求：两类中任意样本观测点 X_i ，到超平面的距离 M_i 应大于等于 d

- $M_i = \frac{|b + \mathbf{w}^T \mathbf{X}_i|}{\|\mathbf{w}\|} \geq d$ ，即： $\frac{y_i(b + \mathbf{w}^T \mathbf{X}_i)}{\|\mathbf{w}\|} \geq d$


若正确预测就要满足

- 即满足约束条件：

$$y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1$$

- 数学问题：

$$\begin{cases} \max_{b, \mathbf{w}} d \\ \text{s.t. } y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1, i = 1, 2, \dots, N \end{cases}$$



完全线性可分下的支持向量分类：理想

- 使 $d = \frac{1}{\|\mathbf{w}\|}$ 最大即使 $\|\mathbf{w}\|$ 最小，为求解方便，求 $\tau(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} \mathbf{w}^T \mathbf{w}$ 最小

- 超平面参数求解的目标函数为：

$$\min_{\mathbf{w}} \tau(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$


- 约束条件为：

$$y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1$$

$$y_i(b + \mathbf{w}^T \mathbf{X}_i) - 1 \geq 0, \quad i = 1, 2, \dots, N$$

- 典型的凸二次型规划求解问题，采用拉格朗日乘子法
 - 定义拉格朗日函数，对参数求偏导并令偏导数等于零，求解


- 单一等式约束条件下的求解
 - 设目标函数为 $f(\mathbf{w})$ ，单一等式约束条件为 $g(\mathbf{w}) = 0$
 - 希望求得在 $g(\mathbf{w}) = 0$ 约束条件下 $f(\mathbf{w})$ 取最小值时的 $\mathbf{w}$ （最优解）
 - 假设 $f(\mathbf{w}) = w_1^2 + w_2^2$
 - $g(\mathbf{w}) = w_1 + w_2 - 1 = 0$



蓝色小箭头所指方向为 $f(\mathbf{w})$ 的负梯度方向

- 最优解在切点C处

- 单一不等式约束条件下的求解
 - 假设 $f(\mathbf{w}) = w_1^2 + w_2^2$
 - $g(\mathbf{w}) = w_1 + w_2 - 1 \leq 0$ 或 $g(\mathbf{w}) = w_1 + w_2 + 1 \leq 0$



蓝色小箭头所指方向为
 $f(\mathbf{w})$ 的负梯度方向

- 第一种情况： $f(\mathbf{w})$ 的最小值在可行域内
- 第二种情况： $f(\mathbf{w})$ 的最小值在可行域的边界 $g(\mathbf{w}) = 0$ 与 $f(\mathbf{w})$ 等高线相切点C处
- 点C处的特点： $f(\mathbf{w})$ 梯度和 $g(\mathbf{w})$ 的梯度共线但方向相反

$$\nabla f(\mathbf{w}) = -\alpha \nabla g(\mathbf{w}) \quad \text{方向相反有 } \alpha > 0 \text{ 成立}$$


$$\nabla(f(\mathbf{w}) + \alpha g(\mathbf{w})) = 0$$

- 对函数 $L(\mathbf{w}, \alpha) = f(\mathbf{w}) + \alpha g(\mathbf{w})$ 的参数求导，并令导数等于零。 $L(\mathbf{w}, \alpha)$ 称为拉格朗日函数， $\alpha \geq 0$ 称为拉格朗日乘子
- $\alpha = 0$ 对应情况一，将两种情况统一表述为： $\alpha g(\mathbf{w}) = 0$

• 单一不等式约束条件下的求解

- 假设 $f(\mathbf{w}) = w_1^2 + w_2^2$
- $g(\mathbf{w}) = w_1 + w_2 - 1 \leq 0$ 或 $g(\mathbf{w}) = w_1 + w_2 + 1 \leq 0$

蓝色小箭头所指方向为 $f(\mathbf{w})$ 的负梯度方向



• KKT (Karush-Kuhn-Tucker, KKT) 条件

$$\begin{cases} \nabla L(\mathbf{w}, \alpha) = \nabla f(\mathbf{w}) + \nabla \alpha g(\mathbf{w}) = 0 \\ g(\mathbf{w}) \leq 0 \\ \alpha \geq 0 \\ \alpha g(\mathbf{w}) = 0 \end{cases}$$

$$\min_{\mathbf{w}} \tau(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$y_i(b + \mathbf{w}^T \mathbf{X}_i) - 1 \geq 0, \quad i = 1, 2, \dots, N$$

• 支持向量分类超平面参数的求解

- 构造拉格朗日函数: $L(\mathbf{w}, \alpha) = f(\mathbf{w}) + \alpha g(\mathbf{w})$

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i (y_i(b + \mathbf{w}^T \mathbf{X}_i) - 1)$$

- 对 $\mathbf{w}$ 和 b 求偏导并令偏导数等于0

$$\sum_{i=1}^N \alpha_i y_i \mathbf{X}_i = \mathbf{w} \quad \sum_{i=1}^N \alpha_i y_i = 0$$

- 超平面系数向量 $\mathbf{w}$ 是所有 $\alpha_i \neq 0$ 的样本观测的 $y_i \mathbf{X}_i$ 的线性组合
- $\alpha_i = 0$ 的样本观测对超平面不起作用
- $\alpha_i > 0$ 的点对超平面的系数向量产生影响, 这样的点即为 **支持向量--最大边界超平面由支持向量决定**
- KKT条件知: 支持向量落在两类的边界线上 $\alpha g(\mathbf{X}) = 0$

对偶问题: $\max L(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{X}_i^T \mathbf{X}_j)$

完全线性可分下的支持向量分类：理想

- 有 L 个支持向量： $\hat{\mathbf{w}} = \sum_{i=1}^L \alpha_i y_i \mathbf{X}_i$
 - 可从 L 个支持向量中任选一个 $\mathbf{X}_i$ ，代入平行边界线方程计算得到： $b = y_i - \hat{\mathbf{w}}^T \mathbf{X}_i$
 $b + \hat{\mathbf{w}}^T \mathbf{X}^+ = 1$; $b + \hat{\mathbf{w}}^T \mathbf{X}^- = -1$
 - 为得到 b 的更稳定的估计，可随机多选些支持向量 $\mathbf{X}_i$ ，用多个 b 的均值作为最终的估计值
- 支持向量分类的预测
 - 依分类超平面对新样本观测 $\mathbf{X}_0$ 进行预测时，只需关注符号

$$\begin{aligned} h(\mathbf{X}_0) &= \text{Sign}(b + \hat{\mathbf{w}}^T \mathbf{X}_0) = \text{Sign}\left[b + \sum_{i=1}^L (\alpha_i y_i \mathbf{X}_i^T) \mathbf{X}_0\right] \\ &= \text{Sign}\left[b + \sum_{i=1}^L \alpha_i y_i (\mathbf{X}_i^T \mathbf{X}_0)\right] \end{aligned}$$

- 若 $h(\mathbf{X}_0) > 0$ ， $\hat{y}_0 = 1$ ；若 $h(\mathbf{X}_0) < 0$ ， $\hat{y}_0 = -1$

Python模拟与启示：完全线性可分下支持向量分类的实现

Chapter7-2.ipynb




```

1 N = 100
2 X, y = make_classification(n_samples=N, n_features=2, n_redundant=0, n_informative=2, class_sep=1, random_state=1, n_clusters_per_class=1)
3 X_train, X_test, y_train, y_test = train_test_split(X, y, train_size=0.85, random_state=123)
4 X01, X02 = np.meshgrid(np.linspace(X_train[:, 0].min(), X_train[:, 0].max(), 500), np.linspace(X_train[:, 1].min(), X_train[:, 1].max(), 500))
5 X0 = np.hstack((X01.reshape((len(X01)*len(X02), 1)), X02.reshape((len(X01)*len(X02), 1))))
6 modelSVC = svm.SVC(kernel='linear', C=2) #modelSVC=svm.LinearSVC(C=2, dual=False)
7 modelSVC.fit(X_train, y_train)
8 print('超平面的常数项b: ', modelSVC.intercept_)
9 print('超平面系数w: ', modelSVC.coef_)
10 print('支持向量的个数: ', modelSVC.n_support_)
11 Y0 = modelSVC.predict(X0)
12 plt.figure(figsize=(7, 5))
13 plt.scatter(X0[np.where(Y0==1), 0], X0[np.where(Y0==1), 1], c='lightgray')
14 plt.scatter(X0[np.where(Y0==0), 0], X0[np.where(Y0==0), 1], c='mistyrose')
15 for k, m in [(1, '^'), (0, 'o')]:
16     plt.scatter(X_train[y_train==k, 0], X_train[y_train==k, 1], marker=m, s=40)
17     plt.scatter(X_test[y_test==k, 0], X_test[y_test==k, 1], marker=m, s=40, c='', edgecolors='g')
18 plt.scatter(modelSVC.support_vectors[:, 0], modelSVC.support_vectors[:, 1], marker='o', c='b', s=120, alpha=0.3)
19 plt.title('线性可分下的支持向量机最大边界超平面', fontsize=14)
20 plt.xlabel('X1', fontsize=14)
21 plt.ylabel('X2', fontsize=14)
22 plt.grid(True, linecolor='gray')

```

后续解释！

超平面的常数项b: [0.00427528]
 超平面系数w: [[-1.75478826 0.07731007]]
 支持向量的个数: [1 2]



• 案例六的SVM多分类预测：完全线性可分


```
X = data[['frontal', 'vertical']]
y = data['Activity'].astype(int)
X01,X02 = np.meshgrid(np.linspace(X['frontal'].min(),X['frontal'].max(),200),
                      np.linspace(X['vertical'].min(),X['vertical'].max(),200))
X0 = np.hstack((X01.reshape(len(X01)*len(X02),1),X02.reshape(len(X01)*len(X02),1)))
modelSVC = svm.SVC(kernel='linear',C=0.01)
modelSVC.fit(X,y)
print(classification_report(y,modelSVC.predict(X)))
Y0hat = modelSVC.predict(X0).reshape(X01.shape)
plt.figure(figsize=(9,6),dpi=150)
plt.contourf(X01,X02,Y0hat,alpha=0.4,cmap=plt.cm.coolwarm)
for k,m in zip(K,M):
    plt.scatter(X.loc[y==k,'frontal'],X.loc[y==k,'vertical'],marker=m,s=40,label=f'{k}:{label[k-1]}')
plt.xlabel('frontal',fontsize=14)
plt.ylabel('vertical',fontsize=14)
plt.title('支持向量机最大边界超平面\n(训练误差=%.2f,支持向量:%s)%(1-modelSVC.score(X,y),modelSVC.n_support_),fontsize=14)
plt.grid(True,linestyle='-.')
plt.legend()
```

后续解释!



	precision	recall	f1-score	support
1	0.54	0.81	0.65	1244
2	0.00	0.00	0.00	530
3	0.99	1.00	0.99	20537
4	0.00	0.00	0.00	335
accuracy			0.95	22646
macro avg	0.38	0.45	0.41	22646
weighted avg	0.93	0.95	0.94	22646

• 问:


- 预测效果理想吗? 为什么?
- 可尝试改进方向?




- 问：可尝试改进方向？
 - 完全线性可分下的约束条件过于严苛，不现实
 - 应允许部分样本观测点进入“禁区”（间隔）



- 完全线性可分下的约束条件过于严苛，会受到极端值的影响
- 广义线性可分下的超平面：
 - 采用适当的宽松策略，允许部分样本观测点进入“禁区”（间隔）——广义线性或线性软间隔支持向量分类



- 广义线性可分下的超平面：采用适当的**宽松策略**，允许部分样本观测点进入“禁区”（间隔）：**广义线性或线性软间隔支持向量分类**



- 问：
 - 若允许样本观测点**随意**进入禁区的后果？
 - 需先对进入“禁区”的“深度”进行度量：将进入边界内部的样本观测点 X_i ，到所属类的边界(虚线)的距离记为 e_i
 - $e_i < d$ 意味着什么？
 - $e_i > d$ 意味着什么？


- 宽松条件下实现**正确分类**($e_i < d$)的**数学表达**：**几何角度的思考**

- 正确分类的样本观测点 X_i ，到超平面的距离 M_i 均：

$$M_i = \frac{|b + \mathbf{w}^T \mathbf{X}_i|}{\|\mathbf{w}\|} \geq (d - e_i) \quad \text{若正确预测就要满足} \quad \frac{y_i(b + \mathbf{w}^T \mathbf{X}_i)}{\|\mathbf{w}\|} \geq (d - e_i)$$





- 广义线性可分下的超平面：采用适当的宽松策略，允许部分样本观测点进入“禁区”（间隔）：广义线性或线性软间隔支持向量分类



$$\frac{y_i(b + \mathbf{w}^T \mathbf{X}_i)}{\|\mathbf{w}\|} \geq (d - e_i)$$

- 因 $d = \frac{1}{\|\mathbf{w}\|}$ ，若记 $\xi_i = e_i \|\mathbf{w}\| = \frac{e_i}{d}$ (非负, 松弛变量)，广义线性可分下的约束条件为：
 - $y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1 - \xi_i \quad (\xi_i \geq 0, i = 1, 2, \dots, N)$
- 问：
 - ξ_i 的取值和意义是什么？
 - $\xi_i = 0?$, $0 < \xi_i < 1?$, $\xi_i > 1?$
 - SVM 的损失函数是什么，与 ξ_i 的关系？

- 广义线性可分下的超平面：采用适当的**宽松策略**，允许部分样本观测点进入“禁区”（间隔）：广义线性或**线性软间隔支持向量分类**
 - 问：SVM的**损失函数**是什么，与 ξ_i 的关系？
 - 约束条件： $y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1 - \xi_i$
 - $\xi_i \geq 1 - y_i(b + \mathbf{w}^T \mathbf{X}_i)$
 - $(b + \mathbf{w}^T \mathbf{X}_i)$ 的正负符号和大小的**意义**？
 - $y_i(b + \mathbf{w}^T \mathbf{X}_i)$ 的正负符号和大小的**意义**？
 - **hinge(铰链)损失**： $L_i = \max(0, 1 - y_i(b + \mathbf{w}^T \mathbf{X}_i))$
 - $L_i = 0$ ： $\mathbf{X}_i$ 预测正确且在平行边界的外侧 ($M_i \geq d, \xi_i = 0$)
 - $L_i > 0$ ：
 - $\mathbf{X}_i$ 预测正确，但 $M_i < d, 0 < \xi_i < 1$ ，称为**间隔不足**，损失随 $y_i(b + \mathbf{w}^T \mathbf{X}_i)$ 的增加而线性减小
 - $\mathbf{X}_i$ 预测错误 ($\xi_i > 1$)，损失随 $y_i(b + \mathbf{w}^T \mathbf{X}_i)$ 减少而线性增加
 - 在大多数区域可微
 - 问：
 - $\xi_i \geq 1 - y_i(b + \mathbf{w}^T \mathbf{X}_i)$ 体现了**宽松策略**，允许有损失但太宽松导致的问题？



- 问：

- $\xi_i \geq 1 - y_i(b + \mathbf{w}^T \mathbf{X}_i)$ 体现 **宽松** 策略，允许有损失但太宽松导致的问题？

- 只要 ξ_i 足够大就总能满足约束条件

- 显然应避免 ξ_i 过大

$$\text{约束条件: } y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1 - \xi_i$$

- 因此：

- 允许少量 $\mathbf{X}_i$ 的松弛变量 $\xi_i > 1$ ，但应限制 $\sum_i^N \xi_i < E$ ， E 为一个非负阈值

- 阈值 $E = 0$ ：等同于完全线性可分下的支持向量分类

- 阈值 E 较小：策略“**偏紧**”，不允许较多的样本观测点进入“禁区”或 ξ_i 较大

- 缩小平行边界的宽度，超平面为 **间隔宽度相对较窄** 的超平面

- 阈值 E 较大：策略“**偏松**”，允许较多的样本观测点进入“禁区”或 ξ_i 较大

- 扩大平行边界的宽度，超平面为 **间隔宽度相对较宽** 的超平面

- 阈值 E 的大小决定了间隔的宽度

• 广义线性可分下的超平面



- 通常用对错误分类的惩罚参数 $C > 0$ ，间接体现阈值 E 的大小
- 惩罚参数 C 是根据对预测误差容忍程度而设置的可调参数(超参数)
 - C 越大对误差的容忍度越低，反之

Chapter7-3.ipynb

```

1 N = 100
2 X, y = make_classification(n_samples=N, n_features=2, n_redundant=0, n_informative=2, class_sep=1.2, random_state=1, n_clusters_per_
3 random.seed(2)
4 X+=2*random.uniform(size=X.shape)
5 X_train, X_test, y_train, y_test = train_test_split(X, y, train_size=0.85, random_state=1)
6 X01, X02 = np.meshgrid(np.linspace(X_train[:, 0].min(), X_train[:, 0].max(), 500), np.linspace(X_train[:, 1].min(), X_train[:, 1].max(),
7 X0 = np.hstack((X01.reshape(len(X01)*len(X02), 1), X02.reshape(len(X01)*len(X02), 1)))
8 fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(15, 6))
9 for C, H in [(5, 0), (0.1, 1)]:
10     modelSVC = svm.SVC(kernel='linear', C=C)
11     modelSVC.fit(X_train, y_train)
12     Y0 = modelSVC.predict(X0)
13     axes[H].scatter(X0[np.where(Y0==1)], 0), X0[np.where(Y0==1)],
14     axes[H].scatter(X0[np.where(Y0==0)], 0), X0[np.where(Y0==0)],
15     for k, m in [(1, '^'), (0, 'o')]:
16         axes[H].scatter(X_train[y_train==k, 0], X_train[y_train==k],
17         axes[H].scatter(X_test[y_test==k, 0], X_test[y_test==k],
18         axes[H].scatter(modelSVC.support_vectors_[0], modelSVC.s
19         axes[H].set_title('广义线性可分下的支持向量机最大边界超平
20         axes[H].set_xlabel('X1', fontsize=14)

```



问:

- C 值大小产生什么影响?
 - 间隔宽度、支持向量、误差
 - 为什么? 惩罚大小

- 广义线性可分下的超平面：错误惩罚和目标函数
 - 调整目标函数，将对误差和容忍程度(惩罚参数 C)体现在目标函数中

- 目标函数为：

$$\min_{\mathbf{w}, \xi} \tau(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \boxed{C \sum_{i=1}^N \xi_i} \quad \text{正则化项, } C \text{ 为超参数}$$

- 问：
 - C 指定为一个极小值，如 $C \rightarrow 0$ 会怎样？
 - C 指定为一个极大值，如 $C \rightarrow \infty$ 会怎样？
 - 如何调参？

- 广义线性可分下的超平面参数求解

- 目标函数:
$$\min_{\mathbf{w}, \xi} \tau(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i$$

- 约束条件:
$$\begin{cases} y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1 - \xi_i & (i = 1, 2, \dots, N) \\ \xi_i \geq 0 \end{cases}$$

- 构造拉格朗日函数: $\alpha_i \geq 0, \mu_i \geq 0$ 为拉格朗日乘子

$$L(\mathbf{w}, b, \mathbf{a}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i [y_i(b + \mathbf{w}^T \mathbf{X}_i) - (1 - \xi_i)] - \sum_{i=1}^N \mu_i \xi_i$$

- 求偏导并令导数等于0:
$$\sum_{i=1}^N \alpha_i y_i \mathbf{X}_i = \mathbf{w} \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_i = C - \mu_i$$

- 对偶问题:
$$\max L(\boldsymbol{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{X}_i^T \mathbf{X}_j)$$

- 约束条件:

$$\text{因 } \mu_i = C - \alpha_i \geq 0 \Rightarrow 0 \leq \alpha_i \leq C \text{ and } \sum_{i=1}^N \alpha_i y_i = 0.$$

• 广义线性可分下支持向量的特征

约束条件：

$$\begin{cases} y_i(b + \mathbf{w}^T \mathbf{X}_i) \geq 1 - \xi_i & (i = 1, 2, \dots, N) \\ \xi_i \geq 0 \end{cases}$$

构造拉格朗日函数： $a_i \geq 0, \mu_i \geq 0$ 为拉格朗日乘子

- 因为：KKT条件中的 $\alpha g(\mathbf{X}) = 0$ ：
 - $\alpha_i [y_i(b + \mathbf{w}^T \mathbf{X}_i) - (1 - \xi_i)] = 0$
 - $\mu_i \xi_i = 0$

• 所以：

- 支持向量落在两类边界线上和“禁区”（间隔）内
- 落在边界线上的支持向量 $\mathbf{X}_i$ 的松弛变量 $\xi_i = 0$
- 落在“禁区”内的支持向量 $\mathbf{X}_i$ ，因 $\xi_i > 0$ ，则 $\mu_i = 0$
 - 由 $a_i = C - \mu_i$ 知： $a_i = C$

• 广义线性可分下支持向量的特征

- 因为：KKT条件中的 $\alpha g(\mathbf{X}) = 0$ ：
 - $\alpha_i [y_i(b + \mathbf{w}^T \mathbf{X}_i) - (1 - \xi_i)] = 0$
 - $\mu_i \xi_i = 0$
- 所以：
 - 支持向量落在两类边界线上和“禁区”（间隔）内
 - 落在边界线上的支持向量 $\mathbf{X}_i$ 的松弛变量 $\xi_i = 0$
 - 落在“禁区”内的支持向量 $\mathbf{X}_i$ ，因 $\xi_i > 0$ ，则 $\mu_i = 0$
 - 由 $a_i = C - \mu_i$ 知： $a_i = C$

案例六的SVM多分类预测：完全线性可分→广义线性可分



```
X = data[['frontal', 'vertical']]
y = data['Activity'].astype(int)
X01,X02 = np.meshgrid(np.linspace(X['frontal'].min(),X['frontal'].max(),200),
                        np.linspace(X['vertical'].min(),X['vertical'].max(),200))
X0 = np.hstack((X01.reshape(len(X01)*len(X02),1),X02.reshape(len(X01)*len(X02),1)))
modelSVC = svm.SVC(kernel='linear',C=50)
modelSVC.fit(X,y)
print(classification_report(y,modelSVC.predict(X)))
Y0hat = modelSVC.predict(X0).reshape(X01.shape)
plt.figure(figsize=(9,6),dpi=150)
plt.contourf(X01,X02,Y0hat,alpha=0.4,cmap=plt.cm.nipy_spectral)
for k,m in zip(K,M):
    plt.scatter(X.loc[y==k,'frontal'],X.loc[y==k,'vertical'],s=m)
plt.xlabel('frontal',fontsize=14)
plt.ylabel('vertical',fontsize=14)
plt.title('支持向量机最大边界超平面\n(训练误差=%.2f,支持向量:\n(1-modelSVC.score(X,y),modelSVC.r
```

后续解释!

完全线性可分策略

广义线性可分策略

	precision	recall	f1-score	support		precision	recall	f1-score	support
1	0.54	0.81	0.65	1244	1	0.69	0.84	0.76	1244
2	0.00	0.00	0.00	530	2	0.76	0.74	0.75	530
3	0.99	1.00	0.99	20537	3	0.99	1.00	1.00	20537
4	0.00	0.00	0.00	335	4	0.00	0.00	0.00	335
accuracy			0.95	22646	accuracy			0.97	22646
macro avg	0.38	0.45	0.41	22646	macro avg	0.61	0.64	0.63	22646
weighted avg	0.93	0.95	0.94	22646	weighted avg	0.96	0.97	0.96	22646




问:


- 还能再优化吗?
- 尝试空间变换

- 空间变换：解决线性不可分问题的常见手段
 - 一般方式是进行非线性空间转换：低维空间中的线性不可分问题，通过恰当的非线性变换转化为高维空间中的线性可分问题

100个样本观测点在二维空间中的分布




三维空间下100个样本观测点的分布



Chapter7-4.ipynb

```
1 N=100
2 X,y=make_circles(n_samples=N,noise=0.2,factor=0.5,random_state=123)
3 fig = plt.figure(figsize=(20,7),dpi=150)
4 markers=['^','o']
5 ax = fig.add_subplot(121)
6 for k,m in zip([1,0],markers):
7     ax.scatter(X[y==k,0],X[y==k,1],marker=m,s=50)
8 ax.set_title('100个样本观测点在二维空间中的分布',fontsize=14)
9 ax.set_xlabel('X1',fontsize=14)
10 ax.set_ylabel('X2',fontsize=14)
11 ax.grid(True,linestyle='-.')
12 var = multivariate_normal(mean=[0,0], cov=[[1,0],[0,1]])
13 Z=np.zeros((len(X),))
14 for i,x in enumerate(X):
15     Z[i]=var.pdf(x)
16 ax = fig.add_subplot(122, projection='3d')
17 for k,m in zip([1,0],markers):
18     ax.scatter(X[y==k,0],X[y==k,1],Z[y==k],marker=m,s=40)
19 ax.set_title('三维空间下100个样本观测点的分布',fontsize=14)
20 ax.set_xlabel('X1',fontsize=14)
21 ax.set_ylabel('X2',fontsize=14)
22 ax.set_zlabel('Z',fontsize=14)
```



线性不可分下的支持向量分类

- 首先, 通过特定的非线性映射函数 $\varphi_M()$, 将原来低维空间中的点 X_i , 映射到 M 维空间 $\mathbb{R}^M$ 中
- 然后, 沿用前述方法, 在空间 $\mathbb{R}^M$ 中寻找最大边界超平面
 - 例如: 原有输入变量 X_1, X_2
 - 映射函数 $\varphi_3(X_1, X_2) = (X_1^2, X_2^2, Z)^T, Z = \sqrt{2}X_1X_2$
 - 三维空间中的超平面: $b + w_1X_1^2 + w_2X_2^2 + w_3Z = 0$
 - 采用了非线性映射函数, 空间 $\mathbb{R}^M$ 中的一个超平面, 在原空间中看起来是一个曲面 (线)
 - 高维空间中的维灾难问题: 待估参数太多
 - $p = 2, d = 2$: 参数个数3
$$\frac{(p + d - 1)!}{d! (p - 1)!}$$

- 支持向量机解决维灾难的方式：**从点积入手**
 - 对偶函数中：点积 $\mathbf{X}_i^T \mathbf{X}_j$ 决定了超平面的参数

$$\max L(\boldsymbol{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{X}_i^T \mathbf{X}_j)$$

- 支持向量分类预测中：预测结果取决于新样本观测 $\mathbf{X}_0$ 与 L 个支持向量输入变量的点积

$$\text{Sign}[b + \sum_{i=1}^L \alpha_i y_i (\mathbf{X}_i^T \mathbf{X}_0)]$$

- 基于非线性映射函数 $\varphi_M()$ ，对 $\mathbf{X}_i$ 和 $\mathbf{X}_0$ 做非线性变换后：

$$\max L(\boldsymbol{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j ([\varphi_M(\mathbf{X}_i)]^T \varphi_M(\mathbf{X}_j))$$

$$\text{Sign}[b + \sum_{i=1}^L \alpha_i y_i ([\varphi_M(\mathbf{X}_i)]^T \varphi_M(\mathbf{X}_0))] \quad \text{点积计算是关键}$$

支持向量机解决维灾难的方式：核函数与非线性变换

- 希望找到一个函数 $K(\mathbf{X}_i, \mathbf{X}_j)$: $K(\mathbf{X}_i, \mathbf{X}_j) \equiv [\varphi_M(\mathbf{X}_i)]^T \varphi_M(\mathbf{X}_j)$

$$\begin{aligned} L(\alpha) &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \left([\varphi_M(\mathbf{X}_i)]^T \varphi_M(\mathbf{X}_j) \right) \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{X}_i, \mathbf{X}_j) \end{aligned}$$

例如：

- 原有 $p = 2$ 的输入变量 X_1, X_2
- 有映射函数 $\varphi_3(X_1, X_2) = (X_1^2, X_2^2, Z)^T, Z = \sqrt{2}X_1X_2$
- 存在函数 $K(\mathbf{X}_i, \mathbf{X}_j) = (\mathbf{X}_i^T \mathbf{X}_j)^2$
- 计算：
 - $\varphi_3(X_{i1}, X_{i2}) = (X_{i1}^2, X_{i2}^2, Z_i)^T, \varphi_3(X_{j1}, X_{j2}) = (X_{j1}^2, X_{j2}^2, Z_j)^T$
 - $[\varphi_3(\mathbf{X}_i)]^T \varphi_3(\mathbf{X}_j) = (X_{i1}^2 X_{j1}^2 + X_{i2}^2 X_{j2}^2 + 2X_{i1} X_{i2} X_{j1} X_{j2}) = (X_{i1} X_{j1} + X_{i2} X_{j2})^2 = (\mathbf{X}_i^T \mathbf{X}_j)^2 = K(\mathbf{X}_i, \mathbf{X}_j)$

$$\begin{aligned} & \text{Sign} \left[b + \sum_{i=1}^L \alpha_i y_i \left([\varphi_M(\mathbf{X}_i)]^T \varphi_M(\mathbf{X}_0) \right) \right] \\ &= \text{Sign} \left[b + \sum_{i=1}^L \alpha_i y_i K(\mathbf{X}_i, \mathbf{X}_0) \right] \end{aligned}$$

不必通过函数 $\varphi_3(X_1, X_2)$ 进行非线性的空间变换，只需直接在二维空间中计算 $K(\mathbf{X}_i, \mathbf{X}_j)$ 即可

• 支持向量机解决维灾难的方式：核函数与非线性变换

• 核函数：通常用于测度两个样本观测 $\mathbf{X}_i, \mathbf{X}_j$ 的相似度

• **线性核函数**： $K(\mathbf{X}_i, \mathbf{X}_j) = (\mathbf{X}_i^T \mathbf{X}_j) = \sum_{p=1}^P X_{ip} X_{jp}$ ，两个样本观测 $\mathbf{X}_i, \mathbf{X}_j$ 的简单相关系数（已标准化）

• 线性核函数 $K(\mathbf{X}_i, \mathbf{X}_j)$ 等于原空间中 $\mathbf{X}_i, \mathbf{X}_j$ 的点积

$$\max L(\mathbf{a}) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N a_i a_j y_i y_j (\mathbf{X}_i^T \mathbf{X}_j)$$

• 常见的其他核函数

• **d 阶-多项式核**： $K(\mathbf{X}_i, \mathbf{X}_j) = (1 + \gamma \mathbf{X}_i^T \mathbf{X}_j)^d$

• **径向基核**（Radial Basis Function, RBF Kernel）：

• **Sigmoid核**：

$$K(\mathbf{X}_i, \mathbf{X}_j) = \frac{1}{1 + e^{-\gamma \|\mathbf{X}_i - \mathbf{X}_j\|^2}}$$

$$K(\mathbf{X}_i, \mathbf{X}_j) = e^{\frac{-\|\mathbf{X}_i - \mathbf{X}_j\|^2}{2\sigma^2}} = e^{-\gamma \|\mathbf{X}_i - \mathbf{X}_j\|^2}, \quad \gamma = \frac{1}{2\sigma^2}$$

• 问：

• 得到什么启示？低维空间向高维空间的“隐式”变换

• 如何选择核函数？


• Python模拟与启示：核函数的选择和惩罚参数C

```

1 X01,X02 = np.meshgrid(np.linspace(X[:,0].min(),X[:,0].max(),500),np.linspace(X[:,1].min(),X[:,1].max(),500))
2 X0 = np.hstack((X01.reshape(len(X01)*len(X02),1),X02.reshape(len(X01)*len(X02),1)))
3 fig,axes = plt.subplots(nrows=2,ncols=2,figsize=(15,12))
4 for C,ker,H,L in [(0.01,'poly',0,0),(1,'rbf',0,1),(10,'poly',1,0),(1000,'rbf',1,1)]:
5     modelSVC = svm.SVC(kernel=ker,C=C)
6     modelSVC.fit(X,y)
7     Y0 = modelSVC.predict(X0)
8     axes[H,L].scatter(X0[np.where(Y0==1),0],X0[np.where(Y0==1),1],c='blue')
9     axes[H,L].scatter(X0[np.where(Y0==0),0],X0[np.where(Y0==0),1],c='orange')
10    for k,m in [(1,'^'),(0,'o')]:
11        axes[H,L].scatter(X[y==k,0],X[y==k,1],marker=m,s=40)
12    axes[H,L].scatter(modelSVC.support_vectors_[0],modelSVC.support_vectors_[1])
13    axes[H,L].set_xlabel('X1')
14    axes[H,L].set_ylabel('X2')
15    axes[H,L].set_title('线性不可分下的支持向量机最大边界超平面\n(C=%s,ker=%s,训练误差=%s,支持向量=%s)'
16                        % (C,ker,1-modelSVC.score(X,y),modelSVC.n_supports_))
17    axes[H,L].grid(True,linestyle='-.')

```


Chapter7-4.ipynb




• 案例六的SVM多分类预测：完全线性可分→广义线性可分→引入核函数

```
kernels = ['poly', 'rbf'] #degree默认3
fig = plt.figure(figsize = (9,15), dpi = 150)
for i,ker in enumerate(kernels,start = 1):
    modelSVC = svm.SVC(kernel = ker,C = 50)
    modelSVC.fit(X,y)
    print('核函数=%s\n'%ker,classification_report(y,modelSVC.predict(X)))
    YOhat = modelSVC.predict(X0).reshape(X01.shape)
    plt.subplot(2,1,i)
    plt.contourf(X01, X02, YOhat, alpha=0.4, cmap = plt.cm.coolwarm)
    for k,m in zip(K,M):
        plt.scatter(X.loc[y == k,'frontal'],X.loc[y == k,'vertical'],marker = m,s = 40,label = f'{k}: {label[k-1]}')
    plt.xlabel('frontal',fontsize = 14)
    plt.ylabel('vertical',fontsize = 14)
    plt.title('支持向量机最大边界超平面\n(Kernal=%s, 训练误差=%.2f, 支持向量:%s)'%
              (ker,1-modelSVC.score(X,y),modelSVC.n_support_),fontsize = 14)
    plt.grid(True,linestyle='-.')
```


支持向量机最大边界超平面
(训练误差=0.03, 支持向量:[810 416 184 335])



支持向量机最大边界超平面
(Kernal=poly, 训练误差=0.03, 支持向量:[718 310 171 335])



支持向量机最大边界超平面
(Kernal=rbf, 训练误差=0.03, 支持向量:[677 273 158 324])



- 案例六的SVM多分类预测：完全线性可分→广义线性可分→引入核函数

广义线性可分策略

	precision	recall	f1-score	support
1	0.69	0.84	0.76	1244
2	0.76	0.74	0.75	530
3	0.99	1.00	1.00	20537
4	0.00	0.00	0.00	335
accuracy			0.97	22646
macro avg	0.61	0.64	0.63	22646
weighted avg	0.96	0.97	0.96	22646

核函数=poly				
	precision	recall	f1-score	support
1	0.70	0.84	0.76	1244
2	0.76	0.77	0.76	530
3	0.99	1.00	1.00	20537
4	0.00	0.00	0.00	335
accuracy			0.97	22646
macro avg	0.61	0.65	0.63	22646
weighted avg	0.96	0.97	0.96	22646
核函数=rbf				
	precision	recall	f1-score	support
1	0.72	0.87	0.79	1244
2	0.83	0.73	0.78	530
3	1.00	1.00	1.00	20537
4	0.59	0.12	0.20	335
accuracy			0.97	22646
macro avg	0.78	0.68	0.69	22646
weighted avg	0.97	0.97	0.97	22646

- 结论：尽管总的训练误差没有减少，但径向基核函数更优！
- 问：
 - 还有什么问题？查准率
 - 可做哪些尝试？考虑更多因素，提高模型复杂度(引入更多输入变量)

- 案例六的SVM多分类预测：完全线性可分→广义线性可分→引入核函数
 - 尝试通过添加更多输入变量，提高查准率

```
y = data['Activity'].astype(int)
X = data[['frontal', 'vertical', 'lateral', 'RSSI']]
modelSVC = svm.SVC(kernel = 'rbf', C = 50)
modelSVC.fit(X, y)
print(classification_report(y, modelSVC.predict(X)))
```

核函数=rbf

	precision	recall	f1-score	support
1	0.72	0.87	0.79	1244
2	0.83	0.73	0.78	530
3	1.00	1.00	1.00	20537
4	0.59	0.12	0.20	335
accuracy			0.97	22646
macro avg	0.78	0.68	0.69	22646
weighted avg	0.97	0.97	0.97	22646

增加输入变量

	precision	recall	f1-score	support
1	0.70	0.76	0.73	1244
2	0.81	0.70	0.75	530
3	0.99	1.00	0.99	20537
4	0.98	0.27	0.42	335
accuracy			0.97	22646
macro avg	0.87	0.68	0.72	22646
weighted avg	0.97	0.97	0.97	22646

- 问：
 - 第4类预测效果(训练集)理想吗？
 - 查准率还是召回率？F1分数
 - 若不理想，原因是什么？
 - 如何继续改进？
- 注意存在的问题：
 - 均未对超参数C进行调优
 - 未进行数据的标准化处理(重要)
 - 课后自行尝试

- 案例六的SVM多分类预测：完全线性可分→广义线性可分→引入核函数
 - 问：如何继续提升F1得分(尤其是第4类)？
 - 改进策略：不同类赋予不同的错误惩罚
 - 给各类以不同的C： $\text{class_weight}[k]*C$ ，权重是样本量占比的倒数

$$\min_{\mathbf{w}, \xi} \tau(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i$$

```
y = data['Activity'].astype(int)
X = data[['frontal', 'vertical', 'lateral', 'RSSI']]
modelSVC = svm.SVC(kernel = 'rbf', C = 50, class_weight = 'balanced')
modelSVC.fit(X, y)
print(classification_report(y, modelSVC.predict(X)))
```

	precision	recall	f1-score	support
1	0.70	0.76	0.73	1244
2	0.81	0.70	0.75	530
3	0.99	1.00	0.99	20537
4	0.98	0.27	0.42	335
accuracy			0.97	22646
macro avg	0.87	0.68	0.72	22646
weighted avg	0.97	0.97	0.97	22646



	precision	recall	f1-score	support
1	0.84	0.65	0.73	1244
2	0.64	0.88	0.74	530
3	1.00	1.00	1.00	20537
4	0.55	0.62	0.58	335
accuracy			0.97	22646
macro avg	0.76	0.79	0.76	22646
weighted avg	0.97	0.97	0.97	22646

以precision的下降为代价换取recall的提升,F1得分提高!

支持向量机求解算法的思考

- 关于算法：SMO(Sequential Minimal Optimization)算法,即序列最小优化算法
 - SMO算法1998年由Platt提出，软间隔最大化SVM对偶问题求解算法

$$\max L(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (X_i^T X_j)$$

- 基本思想：
 - 每步优化中，挑选出参数 α 中的两个参数 α_k, α_l 作为“真正的参数”，其余参数都视为常数，将问题转化为类似于二次方程求最大值的问题，从而求出解析解